

M1-HAX710X

Année : 2024-2025

Estimation Ponctuelle

Ludovic Menneteau

1 Généralités

Problématique 1 On considère une v.a. $X : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathcal{X}, \mathcal{B})$ de loi \mathbb{P}_X inconnue. On suppose que \mathbb{P}_X appartient à une famille de loi $(P_\theta)_{\theta \in \Theta}$ indexée par un ensemble Θ et entièrement spécifiée, i.e. qu'il existe $\theta_v \in \Theta$ ($\theta_v : \theta$ vrai) tel que $\mathbb{P}_X = P_{\theta_v}$. Notre objectif est d'étudier des procédures permettant à partir de X , d'obtenir de l'information sur \mathbb{P}_X en estimant θ_v (ou une fonction de θ_v). Comme θ_v peut prendre n'importe quelle valeur dans Θ , les procédures d'estimations devront être évaluées uniformément en θ .

Définition 2 On dit que $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$ est un **modèle statistique** si $(\mathcal{X}, \mathcal{B})$ est un espace mesurable (i.e. \mathcal{X} est un ensemble, \mathcal{B} est une tribu sur \mathcal{X}) et $(P_\theta)_{\theta \in \Theta}$ est une famille de probabilités sur $(\mathcal{X}, \mathcal{B})$ indexée par un ensemble Θ (appelé **ensemble des paramètres** du modèle).

Si $X : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathcal{X}, \mathcal{B})$ est une v.a. telle que \mathbb{P}_X appartient à $(P_\theta)_{\theta \in \Theta}$, on dira que X est **associée** au modèle statistique $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$.

Définition 3 Soient $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$ un modèle statistique et $(\mathcal{Y}, \mathcal{D})$, un espace mesurable.

1. On appelle **statistique** à valeurs dans $(\mathcal{Y}, \mathcal{D})$ toute fonction mesurable $s : \mathcal{X} \rightarrow \mathcal{Y}$ ne dépendant pas de θ .
2. Soit $\varphi : \Theta \rightarrow \varphi(\Theta)$ une fonction telle que $\varphi(\Theta) \subset \mathcal{Y}$. Une statistique $\hat{\varphi} : \mathcal{X} \rightarrow \mathcal{Y}$ est appelée un **estimateur** de $\varphi(\theta)$.

Notations 4 Soit $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$ un modèle statistique.

1. Pour $p \geq 1$, on dit que $h \in \mathcal{L}^p((P_\theta)_{\theta \in \Theta})$ si $h \in \mathcal{L}^p(P_\theta)$ pour tout $\theta \in \Theta$.
2. Soient $h : \mathcal{X} \rightarrow \mathbb{R}$ et $\theta \in \Theta$.
 - (a) Si $h \in \mathcal{L}^1(P_\theta)$, on définit :

$$E_\theta(h) := \int_{\mathcal{X}} h \, dP_\theta.$$

- (b) Si $h \in \mathcal{L}^2(P_\theta)$, on définit :

$$V_\theta(h) := E_\theta\left((h - E_\theta(h))^2\right).$$

- (c) Si g et $h \in \mathcal{L}^2(P_\theta)$, on définit :

$$\text{Cov}_\theta(g, h) := E_\theta((g - E_\theta(g))(h - E_\theta(h))).$$

3. Soient $X : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathcal{X}, \mathcal{B})$ une v.a. associée au modèle statistique $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$ et $\theta \in \Theta$.

- (a) Si $h \in \mathcal{L}^1(P_\theta)$, et si on suppose que $\theta_v = \theta$, alors l'espérance de $h(X) : \mathbb{E}(h(X)) := \int_{\Omega} h(X) d\mathbb{P}$ sera notée $\mathbb{E}_\theta(h(X))$.
- (b) Si $h \in \mathcal{L}^2(P_\theta)$, et si on suppose que $\theta_v = \theta$, alors la variance de $h(X) : \mathbb{V}(h(X)) := \mathbb{E}\left((h(X)) - \mathbb{E}(h(X))^2\right)$ sera notée $\mathbb{V}_\theta(h(X))$.
- (c) Si g et $h \in \mathcal{L}^2(P_\theta)$, et si on suppose que $\theta_v = \theta$, alors la covariance de $g(X)$ et $h(X) :$

$$\mathbb{Cov}(g(X), h(X)) := \mathbb{E}((g(X)) - \mathbb{E}(g(X)) (h(X)) - \mathbb{E}(h(X)))$$

sera notée $\mathbb{Cov}_\theta(g(X), h(X))$.

4. NB : Par le Théorème de transfert, il est clair que :

$$\mathbb{E}_\theta(h(X)) = E_\theta(h), \mathbb{V}_\theta(h(X)) = V_\theta(h) \text{ et } \mathbb{Cov}_\theta(g(X), h(X)) = \text{Cov}_\theta(g, h).$$

Définition 5 Soit $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$ un modèle statistique.
Pour $n \geq 1$, le modèle produit

$$(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})^n := (\mathcal{X}^n, \mathcal{B}^{\otimes n}, (P_\theta^{\otimes n})_{\theta \in \Theta})$$

est appelé **modèle d'échantillonnage** (d'ordre n) associé à $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$.

Rappels 6 Soient $(\mathcal{X}, \mathcal{B})$ est un espace mesurable et ν et μ deux mesures σ -finies sur $(\mathcal{X}, \mathcal{B})$.

1. On dit que ν est **absolument continue** par rapport à μ et on note $\nu \ll \mu$ si l'une des deux conditions équivalentes (par le Théorème de Radon Nycodym) suivantes est vérifiée :
i) $[N \in \mathcal{B} \text{ et } \mu(N) = 0] \Rightarrow [\nu(N) = 0]$.
ii) Il existe $f : \mathcal{X} \rightarrow \mathbb{R}^+$ mesurable telle que $\nu = f \cdot \mu$, i.e. pour tout $B \in \mathcal{B} :$

$$\nu(B) = \int_{\mathcal{X}} \mathbf{1}_B(x) f(x) d\mu(x).$$

On dit que f est une **densité** de ν par rapport à μ .

2. En général, f n'est pas unique puisque toutes autre fonction mesurable positive $\mu - pp$ égale à f convient aussi. On note parfois $\frac{d\nu}{d\mu}$ la classe d'équivalence des densités de ν par rapport à μ , on écrira $f \in \frac{d\nu}{d\mu}$ pour dire que f est une densité de ν par rapport à μ .
3. Si $\nu \ll \mu$ et $\mu \ll \nu$ les mesures sont dites **équivalentes** et on note $\mu \sim \nu$.
Il est facile de voir que cela revient à dire que $\frac{d\nu}{d\mu}$ contient une version f strictement positive (et qu'alors $\frac{1}{f}$ est une version de $\frac{d\mu}{d\nu}$).

Définition 7 Soit $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$ un modèle statistique.

1. On dit que le modèle est **dominé** s'il existe une mesure σ -finie μ sur $(\mathcal{X}, \mathcal{B})$ telle que, $\forall \theta \in \Theta : P_\theta \ll \mu$.

μ est appelée une mesure **dominante** du modèle.

Pour $\theta \in \Theta$, on note f_θ une version de la densité $\frac{dP_\theta}{d\mu}$ et on appelle **fonction de vraisemblance** du modèle par rapport à la mesure dominante μ la fonction :

$$f : (x, \theta) \in \mathcal{X} \times \Theta \mapsto f_\theta(x) \in \mathbb{R}^+.$$

2. On dit que le modèle est **homogène** si toutes les mesures P_θ sont équivalentes.

Remarques 8 1) Comme les f_θ , f dépend non seulement du modèle mais aussi de μ . De plus, comme les densités, la fonction de vraisemblance n'est pas unique en tant que fonction puisque si g est une fonction définie sur $\mathcal{X} \times \Theta$ telle que pour tout $\theta \in \Theta$, $g(\cdot, \theta) = f(\cdot, \theta)$ μ -p.p. (en x), alors g est aussi une fonction de vraisemblance du modèle par rapport à μ (f et g sont deux versions de la même vraisemblance). Dans la suite, lorsque l'on écrit soit f la vraisemblance (resp. la densité), il faut comprendre "une version de la vraisemblance (resp. la densité)".

2) Sans perte de généralité, on peut supposer (si besoin) que μ est une probabilité. En effet, comme μ est σ -finie, on peut trouver $\{A_k : k \in K\}$ une partition mesurable de \mathcal{X} telle que K est dénombrable et $\forall k \in K$, $\mu(A_k) \in]0, \infty[$. Il est facile de voir que, si $(p_k)_{k \in K}$ est une famille de réels strictement positifs telle que $\sum_{k \in K} p_k = 1$, la mesure

$$\nu : B \in \mathcal{B} \mapsto \sum_{k \in K} p_k \frac{\mu(A_k \cap B)}{\mu(A_k)}$$

est une probabilité équivalente à μ et peut donc être choisie comme une mesure dominante du modèle.

Proposition 9 Soit $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$ un modèle statistique dominé par une mesure μ . Alors, pour tout $n \geq 1$, le modèle statistique d'échantillonnage $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})^n$ est dominé par $\mu^{\otimes n}$. De plus si, pour $\theta \in \Theta$, $P_\theta = f_\theta \cdot \mu$ alors $P_\theta^{\otimes n} = f_{\theta, n} \cdot \mu^{\otimes n}$ avec

$$f_{\theta, n} : (x_1, \dots, x_n) \in \mathcal{X}^n \mapsto \prod_{1 \leq j \leq n} f_\theta(x_j).$$

Preuve. On suppose que $P_\theta = f_\theta \cdot \mu$.

Pour $(B_1, \dots, B_n) \in \mathcal{B}^n$,

$$\begin{aligned}
P_\theta^{\otimes n} \left(\prod_{1 \leq j \leq n} B_j \right) &= \prod_{1 \leq j \leq n} P_\theta(B_j) \\
&= \prod_{1 \leq j \leq n} \int_{B_j} f_\theta(x_j) d\mu(x_j) \\
&= \int_{\prod_{1 \leq j \leq n} B_j} \underbrace{\left(\prod_{1 \leq j \leq n} f_\theta(x_j) \right)}_{:= f_{\theta,n}(x_1, \dots, x_n)} d\mu^{\otimes n}(x_1, \dots, x_n)
\end{aligned}$$

Les mesures finies $P_\theta^{\otimes n}$ et $f_{\theta,n} \cdot \mu^{\otimes n}$ coïncidant sur le π système $\left\{ \prod_{1 \leq j \leq n} B_j : (B_1, \dots, B_n) \in \mathcal{B}^n \right\}$, elles coïncident aussi sur $\mathcal{B}^{\otimes n} = \sigma \left\{ \prod_{1 \leq j \leq n} B_j : (B_1, \dots, B_n) \in \mathcal{B}^n \right\}$. ■

Le résultat suivant montre que, si $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$ est un modèle dominé, il existe des mesures dominantes particulières pouvant s'exprimer comme des combinaisons convexes dénombrables des éléments de $(P_\theta)_{\theta \in \Theta}$, ce qui aura un intérêt pour établir certains résultats (par exemple le Théorème 21).

Théorème 10 Soit $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$ un modèle statistique dominé. Alors :

1. Il existe un sous ensemble dénombrable $T \subset \Theta$ tel que :

$$[B \in \mathcal{B} \text{ et } \forall t \in T : P_t(B) = 0] \implies [\forall \theta \in \Theta : P_\theta(B) = 0].$$

2. On pose

$$P^* := \sum_{t \in T} c(t) P_t$$

où $(c(t))_{t \in T}$ est une famille de nombres strictement positifs telle que $\sum_{t \in T} c(t) = 1$. Alors, pour tout $\theta \in \Theta$ et pour toute mesure μ dominant le modèle, on a :

$$P_\theta \ll P^* \ll \mu,$$

(i.e. P^* est une probabilité qui domine le modèle et est dominée par μ).

P^* est appelée une **mesure dominante privilégiée** du modèle.

(NB : P^* est un suprémum de $(P_\theta)_{\theta \in \Theta}$ pour le semi ordre partiel induit par \ll sur l'espace des mesures σ -finies μ sur $(\mathcal{X}, \mathcal{B})$).

Preuve. 1) a) Construction de l'ensemble T :

Soit μ_0 une mesure dominante du modèle. Sans perte de généralités (c.f. la Remarque 8-2), on peut supposer que μ_0 est une probabilité (une mesure bornée suffirait pour l'argument que l'on va développer). Pour tout $\theta \in \Theta$, on considère f_θ une densité de P_θ par rapport à μ_0 . Soit

$$\mathcal{C}_0 = \{\{f_\theta > 0\} : \theta \in \Theta\}$$

et

$$\mathcal{C} = \{\text{unions dénombrables d'éléments de } \mathcal{C}_0\}.$$

On a $\mathcal{C}_0 \subset \mathcal{C} \subset \mathcal{B}$. Montrons que $m := \sup_{C \in \mathcal{C}} \mu_0(C)$ est atteint.

Comme μ_0 est bornée, m est fini. De plus, par définition du sup, il existe, pour tout $n \geq 1$, $C_n \in \mathcal{C}$ tel que :

$$m - \frac{1}{n} \leq \mu_0(C_n) \leq m.$$

On pose alors $C^* := \bigcup_{n \geq 1} C_n$. Une union dénombrable d'unions dénombrables étant dénombrable, on a $C^* \in \mathcal{C}$ et donc $\mu_0(C^*) \leq m$. Par ailleurs, pour tout $n \geq 1$, $C_n \subset C^*$ donc

$$\forall n \geq 1 : m - \frac{1}{n} \leq \mu_0(C^*) \leq m \text{ i.e. } \mu_0(C^*) = m.$$

Comme $C^* \in \mathcal{C}$, il existe $T \subset \Theta$ tel que T est dénombrable et $C^* = \bigcup_{t \in T} \{f_t > 0\}$.

b) Montrons que T convient :

Soit $B \in \mathcal{B}$, tel que $\forall t \in T : P_t(B) = 0$. Montrons que $\forall \theta \in \Theta : P_\theta(B) = 0$.

Pour $\theta \in \Theta$, on a :

$$\begin{aligned} P_\theta(B) &= P_\theta(B \cap C^*) + P_\theta(B \cap (C^*)^c) \\ &\leq \left(\sum_{t \in T} P_\theta(B \cap \{f_t > 0\}) \right) + P_\theta((C^*)^c). \end{aligned}$$

Il suffit donc de montrer que $P_\theta((C^*)^c) = 0$ et que,

$$\forall t \in T : P_\theta(B \cap \{f_t > 0\}) = 0.$$

-) Pour montrer que $P_\theta((C^*)^c) = 0$, observons que

$$\begin{aligned} P_\theta((C^*)^c) &= \int_{\mathcal{X}} \mathbf{1}_{(C^*)^c} f_\theta d\mu_0 = \int_{\{f_\theta > 0\}} \mathbf{1}_{(C^*)^c} f_\theta d\mu_0 \\ &= P_\theta((C^*)^c \cap \{f_\theta > 0\}). \end{aligned}$$

Donc, comme $P_\theta \ll \mu_0$, il suffit de montrer que

$$\mu_0((C^*)^c \cap \{f_\theta > 0\}) = 0.$$

Or, (comme $C^* \cup \{f_\theta > 0\} = C^* \uplus ((C^*)^c \cap \{f_\theta > 0\})$),

$$\mu_0(C^* \cup \{f_\theta > 0\}) = \mu_0(C^*) + \mu_0((C^*)^c \cap \{f_\theta > 0\})$$

de ce fait comme μ_0 est bornée :

$$\mu_0((C^*)^c \cap \{f_\theta > 0\}) = \mu_0(C^* \cup \{f_\theta > 0\}) - \mu_0(C^*).$$

De plus, $C^* \cup \{f_\theta > 0\} \in \mathcal{C}$, d'où par définition de C^* :

$$m = \mu_0(C^*) \leq \mu_0(C^* \cup \{f_\theta > 0\}) \leq m \text{ i.e. } \mu_0(C^* \cup \{f_\theta > 0\}) = \mu_0(C^*) = m,$$

et donc :

$$\mu_0((C^*)^c \cap \{f_\theta > 0\}) = m - m = 0.$$

-) Montrons que, $\forall t \in T : P_\theta(B \cap \{f_t > 0\}) = 0$.

$$\begin{aligned} [P_t(B) = 0] &\Leftrightarrow \left[\int_{\mathcal{X}} \mathbf{1}_B f_t d\mu_0 = 0 \right] \Leftrightarrow [\mathbf{1}_B f_t = 0 \text{ } \mu_0 \text{ p.p.}] \\ &\Leftrightarrow [\mu_0(\{\mathbf{1}_B f_t \neq 0\}) = 0] \Leftrightarrow [\mu_0(B \cap \{f_t > 0\}) = 0] \\ &\implies [P_\theta(B \cap \{f_t > 0\}) = 0] \quad (\text{car } P_\theta \ll \mu_0). \end{aligned}$$

2) Comme $(c(t))_{t \in T}$ est une famille de nombres strictement positifs telle que $\sum_{t \in T} c(t) = 1$, $P^* = \sum_{t \in T} c(t) P_t$ est clairement une probabilité sur $(\mathcal{X}, \mathcal{B})$.
De plus :

$$[P^*(B) = 0] \Leftrightarrow [\forall t \in T : P_t(B) = 0] \xRightarrow{\text{par 1)}} [\forall \theta \in \Theta : P_\theta(B) = 0],$$

donc, $\forall \theta \in \Theta : P_\theta \ll P^*$. Enfin, soit μ une mesure dominante du modèle.
Comme μ domine $(P_\theta)_{\theta \in \Theta}$:

$$[\mu(B) = 0] \implies [\forall t \in T : P_t(B) = 0] \Leftrightarrow [P^*(B) = 0]$$

donc $P^* \ll \mu$. ■

2 Estimation d'une fonction réelle du paramètre

2.1 Biais. Risque quadratique. Comparaison d'estimateurs.

Définition 11 Soient $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$ un modèle statistique et $\varphi : \Theta \rightarrow \varphi(\Theta)$ une fonction telle que $\varphi(\Theta) \subset \mathbb{R}$.

1. Si $\hat{\varphi}$ est un estimateur de $\varphi(\theta) \in \mathbb{R}$ tel que $\hat{\varphi} \in \mathcal{L}^1((P_\theta)_{\theta \in \Theta})$, alors on définit le **biais** de $\hat{\varphi}$ par rapport à $\varphi(\theta)$:

$$B_\theta^\varphi(\hat{\varphi}) := E_\theta(\hat{\varphi}) - \varphi(\theta).$$

Si $\forall \theta \in \Theta$, $B_\theta^\varphi(\hat{\varphi}) = 0$, on dit que $\hat{\varphi}$ est un estimateur **sans biais** de $(\varphi(\theta))_{\theta \in \Theta}$.

2. Si $\hat{\varphi} \in \mathcal{L}^2((P_\theta)_{\theta \in \Theta})$, on définit le **risque (ou écart) quadratique moyen** entre $\hat{\varphi}$ et $\varphi(\theta)$ par

$$R_\theta^\varphi(\hat{\varphi}) := E_\theta((\hat{\varphi} - \varphi(\theta))^2).$$

3. Si $\hat{\varphi}$ et $\tilde{\varphi} \in \mathcal{L}^2((P_\theta)_{\theta \in \Theta})$, on dit que $\hat{\varphi}$ est (uniformément) préférable à $\tilde{\varphi}$ si $\forall \theta \in \Theta$, $R_\theta^\varphi(\hat{\varphi}) \leq R_\theta^\varphi(\tilde{\varphi})$.
Cette relation de préférence introduit une relation de semi ordre partiel sur \mathcal{E}_φ .

4. Si $\mathcal{F}_\varphi \subset \mathcal{L}^2((P_\theta)_{\theta \in \Theta})$, on dit qu'un estimateur $\hat{\varphi}$ est **optimal** sur \mathcal{F}_φ si $\hat{\varphi} \in \mathcal{F}_\varphi$ et s'il est préférable à tout autre estimateur appartenant à \mathcal{F}_φ (en général, l'existence d'un tel estimateur n'est pas garantie).

5. On note

$$\mathcal{E}_\varphi^0 = \{\hat{\varphi} \in \mathcal{L}^2((P_\theta)_{\theta \in \Theta}) : \forall \theta \in \Theta, E_\theta(\hat{\varphi}) = \varphi(\theta)\}$$

la classe des **estimateurs sans biais** de $(\varphi(\theta))_{\theta \in \Theta}$ dans $\mathcal{L}^2((P_\theta)_{\theta \in \Theta})$.

Proposition 12 (Décomposition biais-variance du risque quadratique)

Considérons un modèle statistique $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$ avec $\Theta \subset \mathbb{R}$, une fonction $\varphi : \Theta \rightarrow \varphi(\Theta) \subset \mathbb{R}$ et $\hat{\varphi} \in \mathcal{L}^2((P_\theta)_{\theta \in \Theta})$. Alors :

1. Pour tout $\theta \in \Theta$:

$$R_\theta^\varphi(\hat{\varphi}) = B_\theta^\varphi(\hat{\varphi})^2 + V_\theta(\hat{\varphi}).$$

2. Si $\hat{\varphi} \in \mathcal{E}_\varphi^0$ alors $R_\theta^\varphi(\hat{\varphi}) = V_\theta(\hat{\varphi})$.

Un estimateur optimal dans \mathcal{E}_φ^0 (s'il existe) est donc un estimateur de $(\varphi(\theta))_{\theta \in \Theta}$ sans biais et de variance minimale (**esbvm**).

Preuve. Pour tout $\theta \in \Theta$:

$$\begin{aligned} & E_\theta \left((\hat{\varphi} - \varphi(\theta))^2 \right) \\ &= E_\theta \left(((\hat{\varphi} - E_\theta(\hat{\varphi})) + (E_\theta(\hat{\varphi}) - \varphi(\theta)))^2 \right) \\ &= \underbrace{E_\theta \left((\hat{\varphi} - E_\theta(\hat{\varphi}))^2 \right)}_{=V_\theta(\hat{\varphi})} + 2 \underbrace{(E_\theta(\hat{\varphi}) - \varphi(\theta)) E_\theta((\hat{\varphi} - E_\theta(\hat{\varphi})))}_{=0} + \underbrace{E_\theta \left((E_\theta(\hat{\varphi}) - \varphi(\theta))^2 \right)}_{=B_\theta^\varphi(\hat{\varphi})^2}. \end{aligned}$$

■

En général, il n'existe pas forcément d'esbvm de $(\varphi(\theta))_{\theta \in \Theta}$ (ni même d'esb, voir par exemple en cours du modèle binomial $(B(n, \theta))_{\theta \in \Theta}$).

Le résultat suivant fournit une cns d'existence d'esbvm et montre que, s'il existe un esbvm, il est essentiellement unique.

Proposition 13 Soient $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$ un modèle statistique, $\varphi : \Theta \rightarrow \varphi(\Theta) \subset \mathbb{R}$ et $\hat{\varphi} \in \mathcal{E}_\varphi^0$. Alors :

1. Les deux assertions suivantes sont équivalentes :

- i) $\hat{\varphi}$ est un esbvm de $(\varphi(\theta))_{\theta \in \Theta}$.
- ii) $\forall \tilde{\varphi} \in \mathcal{E}_\varphi^0$ et $\forall \theta \in \Theta : \text{Cov}_\theta(\tilde{\varphi}, \tilde{\varphi} - \hat{\varphi}) = 0$.

2. Si $\widehat{\varphi}$ et $\widetilde{\varphi}$ sont deux esbvm de $(\varphi(\theta))_{\theta \in \Theta}$, alors

$$\forall \theta \in \Theta : \widetilde{\varphi} = \widehat{\varphi} \quad P_{\theta}\text{-p.p.}$$

Preuve. 1) (i) \Rightarrow (ii) : On suppose que $\widehat{\varphi}$ est un esbvm de $(\varphi(\theta))_{\theta \in \Theta}$. Soit $\widetilde{\varphi} \in \mathcal{E}_{\varphi}^0$. Pour $\alpha \in \mathbb{R}$, on pose

$$\widetilde{\varphi}_{\alpha} := (1 - \alpha) \widehat{\varphi} + \alpha \widetilde{\varphi} = \widehat{\varphi} + \alpha (\widetilde{\varphi} - \widehat{\varphi}).$$

Pour tout $\theta \in \Theta$, $\widetilde{\varphi}_{\alpha} \in \mathcal{L}^2(P_{\theta})$ et

$$E_{\theta}(\widetilde{\varphi}_{\alpha}) = (1 - \alpha) E_{\theta}(\widehat{\varphi}) + \alpha E_{\theta}(\widetilde{\varphi}) = (1 - \alpha) \varphi(\theta) + \alpha \varphi(\theta) = \varphi(\theta),$$

donc $\widetilde{\varphi}_{\alpha} \in \mathcal{E}_{\varphi}^0$. De ce fait, par optimalité de $\widehat{\varphi}$ on a

$$\forall \theta \in \Theta : V_{\theta}(\widetilde{\varphi}_{\alpha}) \geq V_{\theta}(\widehat{\varphi}).$$

Or

$$V_{\theta}(\widetilde{\varphi}_{\alpha}) = V_{\theta}(\widehat{\varphi} + \alpha (\widetilde{\varphi} - \widehat{\varphi})) = V_{\theta}(\widehat{\varphi}) + 2\alpha \text{Cov}_{\theta}(\widehat{\varphi}, \widetilde{\varphi} - \widehat{\varphi}) + \alpha^2 V_{\theta}(\widetilde{\varphi} - \widehat{\varphi}).$$

On en déduit que : $\forall \theta \in \Theta, \forall \alpha \in \mathbb{R}$:

$$2\alpha \text{Cov}_{\theta}(\widehat{\varphi}, \widetilde{\varphi} - \widehat{\varphi}) + \alpha^2 V_{\theta}(\widetilde{\varphi} - \widehat{\varphi}) \geq 0. \quad (*)$$

Si $\alpha > 0$, (*) conduit à

$$2 \text{Cov}_{\theta}(\widehat{\varphi}, \widetilde{\varphi} - \widehat{\varphi}) + \alpha V_{\theta}(\widetilde{\varphi} - \widehat{\varphi}) \geq 0.$$

et en faisant $\alpha \downarrow 0^+$, on obtient que $\text{Cov}_{\theta}(\widehat{\varphi}, \widetilde{\varphi} - \widehat{\varphi}) \geq 0$.

Si $\alpha < 0$, (*) conduit à

$$2 \text{Cov}_{\theta}(\widehat{\varphi}, \widetilde{\varphi} - \widehat{\varphi}) + \alpha V_{\theta}(\widetilde{\varphi} - \widehat{\varphi}) \leq 0.$$

En faisant $\alpha \uparrow 0^-$, on obtient que $\text{Cov}_{\theta}(\widehat{\varphi}, \widetilde{\varphi} - \widehat{\varphi}) \leq 0$.

On a donc bien $\text{Cov}_{\theta}(\widehat{\varphi}, \widetilde{\varphi} - \widehat{\varphi}) = 0$.

2) (ii) \Rightarrow (i) : On suppose (ii).

Soient $\widetilde{\varphi} \in \mathcal{E}_{\varphi}^0$ et $\theta \in \Theta$. On a

$$\begin{aligned} V_{\theta}(\widetilde{\varphi}) &= V_{\theta}(\widehat{\varphi} + (\widetilde{\varphi} - \widehat{\varphi})) \\ &= V_{\theta}(\widehat{\varphi}) + 2 \underbrace{\text{Cov}_{\theta}(\widehat{\varphi}, \widetilde{\varphi} - \widehat{\varphi})}_{=0 \text{ par (ii)}} + \underbrace{V_{\theta}(\widetilde{\varphi} - \widehat{\varphi})}_{\geq 0} \geq V_{\theta}(\widehat{\varphi}), \end{aligned}$$

donc $\widehat{\varphi}$ est bien un esbvm.

2) Si $\widehat{\varphi}$ et $\widetilde{\varphi}$ sont deux esbvm de $\varphi(\theta)$, alors $\forall \theta \in \Theta$:

$$\begin{aligned} V_{\theta}(\widetilde{\varphi} - \widehat{\varphi}) &= \text{Cov}_{\theta}(\widetilde{\varphi} - \widehat{\varphi}, \widetilde{\varphi} - \widehat{\varphi}) \\ &= \text{Cov}_{\theta}(\widetilde{\varphi}, \widetilde{\varphi} - \widehat{\varphi}) - \text{Cov}_{\theta}(\widehat{\varphi}, \widetilde{\varphi} - \widehat{\varphi}) \\ &= 0 - 0 = 0 \quad (\text{par 1)}) \end{aligned}$$

Donc il existe $c(\theta) \in \mathbb{R}$ tel que $\widetilde{\varphi} - \widehat{\varphi} = c(\theta) \quad P_{\theta}\text{-p.p.}$ et comme

$$E_{\theta}(\widetilde{\varphi} - \widehat{\varphi}) = \varphi(\theta) - \varphi(\theta) = 0, \quad \text{on obtient que } c(\theta) = 0,$$

et donc $\widetilde{\varphi} = \widehat{\varphi} \quad P_{\theta}\text{-p.p.} \quad \blacksquare$

2.2 Estimateur du maximum de vraisemblance et estimateur des moments

Dans ce court paragraphe, on définit deux procédures d'estimations classiques.

Définition 14 Soient $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$, un modèle statistique dominé par une mesure μ et

$$f : (x, \theta) \in \mathcal{X} \times \Theta \mapsto f_\theta(x) \in \mathbb{R}^+$$

une fonction de vraisemblance associée et soit (X_1, \dots, X_n) un échantillon i.i.d de v.a. associé à ce modèle (i.e. (X_1, \dots, X_n) est associé au modèle produit $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})^n$). On dit que $\hat{\Theta}_n$, est un **estimateur du maximum de vraisemblance** (emv) de $(\theta)_{\theta \in \Theta}$ si

$$\hat{\Theta}_n \in \arg \max_{\theta \in \Theta} \prod_{1 \leq j \leq n} f(X_j, \theta).$$

Remarques 15 1) L'existence et l'unicité d'un emv n'est pas garantie (voir TD 2).

2) On a aussi

$$\hat{\Theta}_n \in \arg \max_{\theta \in \Theta} \sum_{1 \leq j \leq n} \ln f(X_j, \theta)$$

ce qui est parfois plus maniable au niveau des calculs.

3) si $\hat{\Theta}_n$ est un emv de $(\theta)_{\theta \in \Theta}$, $\varphi(\hat{\Theta}_n)$ est appelé emv de $(\varphi(\theta))_{\theta \in \Theta}$.

Définition 16 Soient $(\mathbb{R}, \mathcal{B}(\mathbb{R}), (P_\theta)_{\theta \in \Theta})$, un modèle statistique et soit (X_1, \dots, X_n) un échantillon i.i.d de v.a. associé à ce modèle. On suppose qu'il existe une fonction Ψ et $\ell \geq 1$ tels que $\forall \theta \in \Theta$, $\theta = \Psi(\mathbb{E}_\theta(X_1^k) : 1 \leq k \leq \ell)$ et, pour $1 \leq k \leq \ell$, on pose

$$\bar{X}_n^{(k)} := \frac{1}{n} \sum_{1 \leq j \leq n} X_j^k.$$

Alors

$$\tilde{\Theta}_n := \Psi(\bar{X}_n^{(k)} : 1 \leq k \leq \ell)$$

est appelé **estimateur des moments** de $(\theta)_{\theta \in \Theta}$.

Voir le TD2 pour de multiples exemples.

2.3 Exhaustivité. Amélioration d'estimateurs sans biais.

Rappels 17 Soient $(\mathcal{X}, \mathcal{B}, P)$ un espace probabilisé, $(\mathcal{Y}, \mathcal{D})$, un espace mesurable et $s : \mathcal{X} \rightarrow \mathcal{Y}$ une fonction mesurable.

1. La sous tribu de \mathcal{B}

$$\sigma(s) := \{s^{-1}(D) : D \in \mathcal{D}\}$$

est appelée **tribu engendrée par s** .

2. On montre qu'une fonction $w : \mathcal{X} \rightarrow \mathbb{R}$ est $\sigma(s) - \mathcal{B}(\mathbb{R})$ mesurable ssi il existe $g : \mathcal{Y} \rightarrow \mathbb{R}$ telle que g est $\mathcal{D} - \mathcal{B}(\mathbb{R})$ mesurable et $w = g \circ s$.
3. Pour tout $h \in \mathcal{L}^1(P)$, on peut montrer qu'il existe $w : \mathcal{X} \rightarrow \mathbb{R}$ fonction $\sigma(s) - \mathcal{B}(\mathbb{R})$ mesurable telle que, pour tout $D \in \mathcal{D}$:

$$E_P(w \mathbf{1}_{s^{-1}(D)}) = E_P(h \mathbf{1}_{s^{-1}(D)})$$

(i.e. il existe $g : \mathcal{Y} \rightarrow \mathbb{R}$ telle que pour tout $D \in \mathcal{D}$,

$$E_P((g \circ s) \mathbf{1}_{s^{-1}(D)}) = E_P(h \mathbf{1}_{s^{-1}(D)})).$$

De plus, $w \in \mathcal{L}^1(P)$ et w est unique modulo l'identification des fonctions P -p.s. égales. $w (= g \circ s)$ est notée $E_P(h | s)$ et appelée l'**espérance conditionnelle** (sous P) sachant s de h .
Pour $y \in \mathcal{Y}$, $g(y)$ est aussi notée $E_P(h | s = y)$.

4. On montre que :

(a) L'application

$$h \in \mathcal{L}^1(P) \mapsto E_P(h | s)$$

est linéaire et croissante.

(b) $\forall h \in \mathcal{L}^1(P)$, $\forall v$ fonction $\sigma(s) - \mathcal{B}(\mathbb{R})$ mesurable telle que $v h \in \mathcal{L}^1(P)$:

$$E_P(v h | s) = v E_P(h | s).$$

(c) $\forall h \in \mathcal{L}^1(P)$:

$$E_P(E_P(h | s)) = E_P(h).$$

Définition 18 Soient $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$ un modèle statistique, $(\mathcal{Y}, \mathcal{D})$, un espace mesurable et $s : \mathcal{X} \rightarrow \mathcal{Y}$ une fonction mesurable. On dit que s est une **statistique exhaustive** (par rapport au modèle) si, pour tout $h \in \mathcal{L}^1((P_\theta)_{\theta \in \Theta})$, $E_\theta(h | s)$ ne dépend pas de θ (comme d'habitude, on note E_θ pour E_{P_θ}).
Dans la suite, on notera $E(h | s)$ la valeur commune des $E_\theta(h | s)$.

Remarques 19 1) Intuitivement, une statistique exhaustive est une transformation des données (i.e. de x) qui conserve toute l'information disponible sur θ (voir le Théorème ?? pour plus de précisions à ce propos).
2) L'identité $\text{id}_{\mathcal{X}} : x \in \mathcal{X} \mapsto x$ est évidemment toujours exhaustive (mais n'a aucun intérêt en temps que résumé de l'information).
3) Si s est exhaustive et $b : \mathcal{Y} \rightarrow \mathcal{Y}$ est bijective, alors $b \circ s$ est exhaustive (car $\sigma(b \circ s) = \sigma(s)$).

On va maintenant montrer comment, à partir d'une statistique exhaustive, il est possible d'améliorer un estimateur sans biais initial (via le Théorème 20), et même, parfois, d'obtenir l'esbvm (via le Théorème 24). Voir le TD 4 pour des applications de cette démarche.

Théorème 20 (de Rao Blackwell)

Soient $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$ un modèle statistique, $\hat{\varphi}$ un estimateur sans biais de $\varphi(\theta) \in \mathbb{R}$, $(\mathcal{Y}, \mathcal{D})$ un espace mesurable et $s : \mathcal{X} \rightarrow \mathcal{Y}$ une statistique exhaustive. Alors $\hat{\varphi}_{|s} := E(\hat{\varphi} | s)$ est un estimateur sans biais de $\varphi(\theta)$, de plus, $\hat{\varphi}_{|s}$ est préférable à $\hat{\varphi}$ i.e. $\forall \theta \in \Theta$:

$$E_\theta \left((\hat{\varphi}_{|s} - \varphi(\theta))^2 \right) \leq E_\theta \left((\hat{\varphi} - \varphi(\theta))^2 \right).$$

Preuve. Comme s est exhaustive, $\hat{\varphi}_{|s} = E_\theta(\hat{\varphi} | s)$ ne dépend pas de θ : c'est bien une statistique. De plus, $\forall \theta \in \Theta$:

$$\begin{aligned} E_\theta \left((\hat{\varphi} - \varphi(\theta))^2 | s \right) &= E_\theta \left((\hat{\varphi} - \hat{\varphi}_{|s})^2 | s \right) \\ &\quad + 2E_\theta \left(((\hat{\varphi} - \hat{\varphi}_{|s})(\hat{\varphi}_{|s} - \varphi(\theta))) | s \right) \\ &\quad + E_\theta \left(((\hat{\varphi}_{|s} - \varphi(\theta)))^2 | s \right) \\ (*) \quad &= E_\theta \left((\hat{\varphi} - \hat{\varphi}_{|s})^2 | s \right) + (\hat{\varphi}_{|s} - \varphi(\theta))^2 \\ &\geq (\hat{\varphi}_{|s} - \varphi(\theta))^2, \end{aligned}$$

avec (*) car $\hat{\varphi}_{|s} - \varphi(\theta)$ est $\sigma(s)$ mesurable donc

$$\begin{aligned} &E_\theta \left(((\hat{\varphi} - \hat{\varphi}_{|s})(\hat{\varphi}_{|s} - \varphi(\theta))) | s \right) \\ &= (\hat{\varphi}_{|s} - \varphi(\theta)) E_\theta \left((\hat{\varphi} - \hat{\varphi}_{|s}) | s \right) \\ &= (\hat{\varphi}_{|s} - \varphi(\theta)) (\hat{\varphi}_{|s} - \hat{\varphi}_{|s}) = 0. \end{aligned}$$

On en déduit que :

$$\begin{aligned} E_\theta \left((\hat{\varphi} - \varphi(\theta))^2 \right) &= E_\theta \left(E_\theta \left((\hat{\varphi} - \varphi(\theta))^2 | s \right) \right) \\ &\geq E_\theta \left((\hat{\varphi}_{|s} - \varphi(\theta))^2 \right) .. \end{aligned}$$

■

Le résultat suivant fournit un critère maniable pour établir l'exhaustivité d'une statistique.

Théorème 21 (Critère de factorisation de Fisher Neyman)

Soient $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$ un modèle statistique dominé, $(\mathcal{Y}, \mathcal{D})$, un espace mesurable et $s : \mathcal{X} \rightarrow \mathcal{Y}$ une fonction mesurable.

Les 2 assertions suivantes sont équivalentes :

i) s est exhaustive.

ii) Si μ est une dominante du modèle, alors $\forall \theta \in \Theta$, il existe des fonctions mesurables

$$g_\theta : y \in \mathcal{Y} \mapsto g_\theta(y) \in \mathbb{R}^+$$

et

$$u : x \in \mathcal{X} \mapsto u(x) \in \mathbb{R}^+$$

telles que $P_\theta = f_\theta \cdot \mu$. avec

$$f_\theta : x \in \mathcal{X} \mapsto u(x) g_\theta(s(x)).$$

Preuve. 1) (i) \Rightarrow (ii) : On suppose que s est exhaustive et pour h mesurable positive et $\theta \in \Theta$, on note $E(h | s)$ la valeur commune des $E_\theta(h | s)$.

a) Soit $P^* := \sum_{t \in T} c(t) P_t$ une dominante privilégiée du modèle (voir Théorème 10) Pour tout $\theta \in \Theta$, on considère $f_\theta^* \in \frac{dP_\theta}{dP^*}$ et on veut montrer que f_θ^* est (i.e. admet une version) $\sigma(s)$ -mesurable.

Pour h mesurable positive et tout $s^{-1}(D) \in \sigma(s)$:

$$\begin{aligned} E_*(h \mathbf{1}_{s^{-1}(D)}) &= \sum_{t \in T} c(t) E_t(h \mathbf{1}_{s^{-1}(D)}) \\ &= \sum_{t \in T} c(t) E_t(E_t(h | s) \mathbf{1}_{s^{-1}(D)}) \\ &= \sum_{t \in T} c(t) E_t(E(h | s) \mathbf{1}_{s^{-1}(D)}) \\ &= E_*(E(h | s) \mathbf{1}_{s^{-1}(D)}), \end{aligned}$$

donc $\forall \theta \in \Theta$:

$$E_*(h | s) = E(h | s) = E_\theta(h | s). \quad (*)$$

Et, $\forall B \in \mathcal{B}$, $\forall \theta \in \Theta$:

$$\begin{aligned} E_*(f_\theta^* \mathbf{1}_B) &= E_\theta(\mathbf{1}_B) = E_\theta(E_\theta(\mathbf{1}_B | s)) = E_\theta(E_*(\mathbf{1}_B | s)) \quad (\text{par } (*)) \\ &= E_*(f_\theta^* E_*(\mathbf{1}_B | s)) = E_*(E_*(f_\theta^* E_*(\mathbf{1}_B | s) | s)) \\ &= E_*(E_*(f_\theta^* | s) E_*(\mathbf{1}_B | s)) = E_*(E_*(E_*(f_\theta^* | s) \mathbf{1}_B | s)) \\ &= E_*(E_*(f_\theta^* | s) \mathbf{1}_B), \end{aligned}$$

donc $E_*(f_\theta^* | s) \in \frac{dP_\theta}{dP^*}$ et elle est bien $\sigma(s)$ -mesurable i.e. il existe une fonction mesurable

$$g_\theta : y \in \mathcal{Y} \mapsto g_\theta(y) \in \mathbb{R}^+$$

telle que $P_\theta = (g_\theta \circ s) \cdot P^*$.

b) Soit μ est une dominante quelconque.

$\forall \theta \in \Theta$, on a $P^* \ll \mu$ (c.f. Théorème 10) donc il existe une fonction $u : \mathcal{X} \rightarrow \mathbb{R}^+$ telle que

$$P^* = u \cdot \mu$$

donc, par a), $P_\theta = (u \times (g_\theta \circ s)) \cdot \mu$.

(ii) \Rightarrow (i) : Soient μ est une dominante du modèle,

$$g_\theta : y \in \mathcal{Y} \mapsto g_\theta(y) \in \mathbb{R}^+ \quad (\theta \in \Theta)$$

et

$$u : x \in \mathcal{X} \mapsto u(x) \in \mathbb{R}^+$$

des fonctions mesurables telles que $P_\theta = f_\theta \cdot \mu$. avec $f_\theta = u \times (g_\theta \circ s)$.

a) On considère $P^* := \sum_{t \in T} c(t) P_t$ une dominante privilégiée. Montrons que $\frac{dP_\theta}{dP^*}$ admet une version $f_\theta^* \sigma(s)$ -mesurable.

Si on pose

$$g : y \in \mathcal{Y} \mapsto \sum_{t \in T} c(t) g_t(y),$$

il est facile de voir que $P^* = f^* \cdot \mu$. avec

$$f^* : x \in \mathcal{X} \mapsto u(x) g(s(x)).$$

Pour $\theta \in \Theta$, définissons la fonction $f_\theta^* : \mathcal{X} \rightarrow \mathbb{R}^+$ telle que :

$$\begin{aligned} f_\theta^*(x) &= \frac{g_\theta(s(x))}{g(s(x))} \quad \text{si } g(s(x)) > 0 \\ &= 0 \quad \text{sinon} \end{aligned}$$

Il est clair que f_θ^* est $\sigma(s)$ -mesurable. On va montrer que $f_\theta^* \in \frac{dP_\theta}{dP^*}$.
Pour tout $B \in \mathcal{B}$:

$$E_*(f_\theta^* \mathbf{1}_B) = E_*(f_\theta^* \mathbf{1}_{B \cap \{g \circ s > 0\}}) + E_*(f_\theta^* \mathbf{1}_{B \cap \{g \circ s = 0\}}).$$

Or $E_*(f_\theta^* \mathbf{1}_{B \cap \{g \circ s = 0\}}) = 0$ car $P^*(\{g \circ s = 0\}) \leq P^*(\{f^* = 0\}) = 0$.
On a donc

$$\begin{aligned} E_*(f_\theta^* \mathbf{1}_B) &= E_*(f_\theta^* \mathbf{1}_{B \cap \{g \circ s > 0\}}) = \int_{\mathcal{X}} \mathbf{1}_{B \cap \{g \circ s > 0\}} f_\theta^* f^* d\mu \\ &= \int_{\mathcal{X}} \mathbf{1}_{B \cap \{g \circ s > 0\}} \frac{g_\theta \circ s}{g \circ s} u g \circ s d\mu \\ &= \int_{\mathcal{X}} \mathbf{1}_{B \cap \{g \circ s > 0\}} u g_\theta \circ s d\mu \\ &= \int_{\mathcal{X}} \mathbf{1}_{B \cap \{g \circ s > 0\}} f_\theta d\mu \\ &= P_\theta(B \cap \{g \circ s > 0\}) \underset{(*)}{=} P_\theta(B) \quad \text{i.e. } f_\theta^* \in \frac{dP_\theta}{dP^*}. \end{aligned}$$

Où, au niveau de $(*)$ on a utilisé le fait que $P_\theta(\{g \circ s = 0\}) = 0$
(car $P^*(\{g \circ s = 0\}) = 0$ et $P_\theta \ll P^*$).

b) Soit h une fonction mesurable positive, on va montrer que $\forall \theta \in \Theta$:

$$E_\theta(h \mid s) = E_*(h \mid s) \quad (\text{et donc ne dépend pas de } \theta),$$

ce qui établira l'exhaustivité de s .

Pour tout $\theta \in \Theta$ et tout $s^{-1}(D) \in \sigma(s)$:

$$\begin{aligned} E_\theta(h \mathbf{1}_{s^{-1}(D)}) &= E_*(f_\theta^* h \mathbf{1}_{s^{-1}(D)}) \\ &= E_*(E_*(f_\theta^* h \mathbf{1}_{s^{-1}(D)} \mid s)) \\ &= E_*(E_*(h \mid s) f_\theta^* \mathbf{1}_{s^{-1}(D)}) \quad (\text{car } f_\theta^* \mathbf{1}_{s^{-1}(D)} \text{ est } \sigma(s)\text{-mesurable}) \\ &= E_\theta(E_*(h \mid s) \mathbf{1}_{s^{-1}(D)}) \end{aligned}$$

i.e. $E_\theta(h \mid s) = E_*(h \mid s)$ c.q.f.d. ■

Définition 22 Soient $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$ un modèle statistique, $(\mathcal{Y}, \mathcal{D})$ un espace mesurable et $s : \mathcal{X} \rightarrow \mathcal{Y}$ une statistique. On dit que s est **complète** (ou totale) si :

$$[w \in \mathcal{L}^2((P_\theta)_{\theta \in \Theta}), \sigma(s) - \mathcal{B}(\mathbb{R}) \text{ mesurable et } E_\theta(w) = 0, \forall \theta \in \Theta] \Rightarrow [w = 0 \text{ } P_\theta - \text{p.s. } \forall \theta \in \Theta],$$

i.e. si

$$[g \circ s \in \mathcal{L}^2((P_\theta)_{\theta \in \Theta}) \text{ et } E_\theta(g \circ s) = 0, \forall \theta \in \Theta] \Rightarrow [g \circ s = 0 \text{ } P_\theta - \text{p.s. } \forall \theta \in \Theta].$$

Remarques 23 Dans la définition précédente, on peut remplacer les \mathcal{L}^2 par toutes classes de parties denses dans \mathcal{L}^2 .

Théorème 24 (de Lehmann Scheffé)

Soient $(\mathcal{X}, \mathcal{B}, (P_\theta)_{\theta \in \Theta})$ un modèle statistique, $\hat{\varphi}$ un estimateur sans biais de $\varphi(\theta) \in \mathbb{R}$, $(\mathcal{Y}, \mathcal{D})$ un espace mesurable et $s : \mathcal{X} \rightarrow \mathcal{Y}$ une statistique exhaustive et complète.

Alors $\hat{\varphi}_{|s} := E(\hat{\varphi} \mid s)$ est l'estimateur sans biais optimal de $(\varphi(\theta))_{\theta \in \Theta}$.

Preuve. Soit $\tilde{\varphi}$ un estimateur sans biais de $(\varphi(\theta))_{\theta \in \Theta}$. Comme s est exhaustive, le Théorème de Rao Blackwell assure que $E(\tilde{\varphi} \mid s)$ est un esb préférable à $\tilde{\varphi}$. De plus $E(\hat{\varphi} \mid s) - E(\tilde{\varphi} \mid s)$ est $\sigma(s)$ mesurable et, comme, pour tout $\theta \in \Theta$,

$$\begin{aligned} E_\theta(E(\hat{\varphi} \mid s) - E(\tilde{\varphi} \mid s)) &= E_\theta(E(\hat{\varphi} - \tilde{\varphi} \mid s)) \\ &= E_\theta(E_\theta(\hat{\varphi} - \tilde{\varphi} \mid s)) \\ &= E_\theta(\hat{\varphi} - \tilde{\varphi}) = \varphi(\theta) - \varphi(\theta) = 0, \end{aligned}$$

la complétude de s conduit à $E(\hat{\varphi} \mid s) - E(\tilde{\varphi} \mid s) = 0$ i.e. $E(\hat{\varphi} \mid s) = E(\tilde{\varphi} \mid s)$ et $E(\hat{\varphi} \mid s)$ est donc préférable à $\tilde{\varphi}$. ■